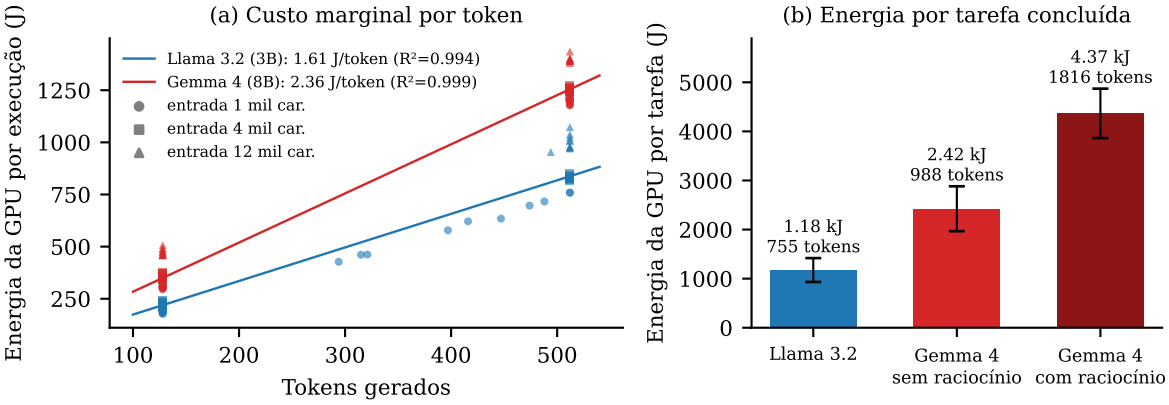
(a) Custo marginal por token
Llama 3.2 (3B): 1.61 J/token (R²=0.994)
Gemma 4 (8B): 2.36 J/token (R²=0.999)
entrada 1 mil car.
entrada 4 mil car.
entrada 12 mil car.
Energia da GPU por execução (J)
250
500
750
1000
1250
100
200
300
400
500
Tokens gerados
(b) Energia por tarefa concluída
Energia da GPU por tarefa (J)
0
1000
2000
3000
4000
5000
1.18 kJ
755 tokens
2.42 kJ
988 tokens
4.37 kJ
1816 tokens
Llama 3.2
Gemma 4
sem raciocínio
Gemma 4
com raciocínio